

ETL-Project: First Delivery

Autores:

Santiago Lourido Rodríguez

Código: 2248394

santiago.lourido@uao.edu.co

Laura Valentina Loaiza Díaz

Código: 2248519

laura_val.loaiza@uao.edu.co

Sebastián Alejandro Jiménez Solís

Código: 2248450

sebastian.jimenez_s@uao.edu.co

Carlos Fabián Cordoba Duque

Código: 2247550

carlos_fab.cordoba@uao.edu.co

Docente:

Daniel Bernal

Facultad:

Ingeniería y Ciencias Básicas

Curso:

ETL

Cali – Valle del cauca

14 de septiembre de 2026



1. Resumen ejecutivo

Este informe documenta el diseño y la implementación de un pipeline ETL completo sobre los microdatos de la Gran Encuesta Integrada de Hogares (GEIH) del DANE, orientado a analizar la pobreza y la pobreza extrema en Colombia en el marco del ODS 1: Fin de la Pobreza.

El pipeline extrae dos archivos CSV (hogares y personas), los modela en un esquema de galaxia con dos tablas de hechos y cuatro dimensiones, los migra a PostgreSQL gestionado en Supabase, y responde las preguntas de negocio mediante consultas SQL ejecutadas contra la base de datos, no contra los archivos originales.

2. El dataset seleccionado y por qué

2.1 Justificación frente al ODS

El ODS 1 de la Agenda 2030 busca poner fin a la pobreza en todas sus formas. Su primera meta se mide sobre la proporción de población que vive por debajo de una línea internacional de pobreza, y su segunda meta sobre las líneas de pobreza nacionales. El dataset elegido contiene exactamente ese tipo de medición para Colombia: el DANE calcula el ingreso per cápita de la unidad de gasto (ingpcug) y lo contrasta con la línea de pobreza (lp) y la línea de indigencia (li), produciendo las banderas oficiales pobre e indigente.

Es decir, no se trata de un dataset del que haya que *inferir* pobreza mediante proxies: es la fuente con la que el país produce su estadística oficial de pobreza monetaria. Eso hace que el vínculo con el ODS sea directo y verificable.

2.2 Por qué dos archivos y no uno

Hogares.csv responde dónde y con qué profundidad ocurre la pobreza, pero no dice quiénes la viven. Personas.csv aporta sexo, edad, nivel educativo, condición laboral e ingresos individuales, y comparte con el primero la llave directorio + secuencia_p. Usar ambos permite cruzar la condición de pobreza del hogar con las características de sus integrantes, que es donde están las preguntas más interesantes del proyecto (multiempleo, baja remuneración, educación).

3. Requerimientos y criterios de evaluación de las fuentes

3.1 Requerimientos del análisis

Requerimientos funcionales

1. Cuantificar la incidencia de pobreza y pobreza extrema a nivel nacional, departamental y por tipo de zona (capital, resto urbano, rural).

2. Medir la profundidad de la pobreza, no solo su incidencia, mediante una brecha de ingreso respecto de cada línea.
3. Relacionar el tamaño del hogar con la probabilidad de estar en pobreza extrema.
4. Caracterizar a las personas en pobreza extrema por sexo, edad, nivel educativo y situación laboral.
5. Entregar todas las respuestas como consultas ejecutables sobre una base de datos relacional, con visualizaciones asociadas.

Requerimientos no funcionales

6. Toda cifra agregada debe ser estadísticamente representativa: ponderada por el factor de expansión, nunca contando filas.
7. Los agregados de variables monetarias deben ser robustos a la asimetría de la distribución del ingreso.
8. Las decisiones de limpieza deben quedar documentadas y ser reproducibles; no se imputa ni se elimina sin justificación escrita.
9. Las credenciales de la base de datos no pueden quedar en el código versionado.
10. El pipeline debe poder re-ejecutarse de principio a fin por cualquier integrante del equipo sin configuración manual adicional más allá de sus credenciales.

3.2 Criterios de evaluación aplicados a las fuentes

Se evaluaron los cuatro criterios exigidos por la rúbrica: disponibilidad, relevancia, estructura y calidad.

Hogares.csv — grano hogar

Criterio	Evaluación
Disponibilidad	Microdato público del DANE, descargable sin costo ni restricción, acompañado de ficha técnica y diccionario de variables. Formato CSV plano, sin dependencias de licencia
Relevancia	Contiene las variables de medición oficial de pobreza monetaria (ingpcug, lp, li, pobre, indigente, npobres, nindigentes). Vínculo directo con el ODS 1
Estructura	276.666 filas × 23 columnas. Llave directorio + secuencia_p verificada como única (0 duplicados). Rangos de li y lp contrastados contra los valores oficiales del DANE: sin valores fuera de rango. Supera el mínimo de la rúbrica (10.000 filas / 10 variables)

Calidad	Nulos concentrados en tres columnas y todos estructurales: p5100 (96,7 %) y p5130 (40,5 %) dependen del tipo de tenencia de vivienda; ciudad_sinam (33,4 %) solo aplica a hogares residentes en ciudad capital. Ninguna variable del análisis de pobreza presenta nulos. 2.195 hogares (0,79 %) con ingreso total ≤ 0 se marcaron con bandera en vez de eliminarse. Discrepancia nper vs npersug en 1.225 filas (0,44 %), esperable por definición metodológica
---------	--

Personas.csv — grano persona

Criterio	Evaluación
Disponibilidad	Mismo origen, vigencia y ficha técnica que Hogares.csv
Relevancia	Aporta las dimensiones individuales (sexo, edad, educación, empleo, ingreso) necesarias para las preguntas de personas
Estructura	773.932 filas $\times$ 133 columnas, de las cuales se seleccionaron 23 para el análisis. Llave directorio + secuencia_p + orden; comparte directorio + secuencia_p con hogares, habilitando la relación 1 hogar $\rightarrow$ N personas sin ambigüedad
Calidad	Sin duplicados. El perfilado de nulos se hizo columna por columna cruzando con edad, pet y p6240: en p3042 (nivel educativo) los nulos corresponden mayoritariamente a menores fuera de edad escolar; en p6800 y p6500 a personas cuya actividad principal no es trabajar; en p7040, p7070 y p7045 a personas sin segundo empleo. Todos estructurales $\rightarrow$ no se imputan ni se eliminan. Se detectó además una inconsistencia en pet: personas mayores de 60 años marcadas como población en edad de trabajar, por lo que todo indicador laboral debe filtrar pet y fft conjuntamente

Adecuación conjunta

Ambas fuentes comparten llave natural, período de referencia y diseño muestral (fex_c y fex_dpto comparables). Esto permite construir el esquema de galaxia con dimensiones conformadas sin duplicar atributos ni comprometer la representatividad estadística, siempre que los agregados se calculen ponderados.

Archivo: Personas

Casos: 773.932 | **Variables referenciadas:** 133

Variable	Descripción
directorio	Llave de vivienda

secuencia_p	Llave de hogar
orden	Llave de persona
clase	Clase
dominio	Dominio
ciudad_sinam	Ciudades capitales (sin Área Metropolitana)
mes	Mes
p3271	Sexo
p6040	¿Cuántos años cumplidos tiene?
p6050	Parentesco con el jefe o jefa del hogar
p6090	Afiliación a entidad de seguridad social en salud
p6100	Régimen de seguridad social en salud al que está afiliado
p3042	Nivel educativo más alto alcanzado y último año/grado aprobado
p3042s1	Grado
p3043	Título o diploma de mayor nivel educativo
p6240	Actividad en la que ocupó la mayor parte del tiempo la semana pasada
p6426	Tiempo trabajando en la empresa/negocio de manera continua
p6430	Posición ocupacional en la primera actividad
p6500	Ganancia antes de descuentos el mes pasado en este empleo
p6510	¿Recibió ingresos por horas extras el mes pasado?
p6510s1	Valor recibido por horas extras

p6510s2	¿Incluyó este valor en los ingresos declarados del mes pasado?
p6545	¿Recibió primas (técnica, antigüedad, clima, etc.) el mes pasado?
p6545s1	Valor recibido por primas
p6545s2	¿Incluyó este valor en los ingresos declarados del mes pasado?
p6580	¿Recibió bonificaciones el mes pasado?
p6580s1	Valor recibido por bonificaciones
p6580s2	¿Incluyó este valor en los ingresos declarados del mes pasado?
p6585s1	¿Recibió auxilio o subsidio de alimentación el mes pasado?
p6585s1a1	Valor recibido por subsidio de alimentación
p6585s1a2	¿Incluyó este valor en los ingresos declarados del mes pasado?
p6585s2	¿Recibió auxilio o subsidio de transporte el mes pasado?
p6585s2a1	Valor recibido por subsidio de transporte
p6585s2a2	¿Incluyó este valor en los ingresos declarados del mes pasado?
p6585s3	¿Recibió subsidio familiar el mes pasado?
p6585s3a1	Valor recibido por subsidio familiar
p6585s3a2	¿Incluyó este valor en los ingresos declarados del mes pasado?
p6585s4	¿Recibió subsidio educativo el mes pasado?
p6585s4a1	Valor recibido por subsidio educativo
p6585s4a2	¿Incluyó este valor en los ingresos declarados del mes pasado?

p6590	¿Recibió alimentos como parte de pago el mes pasado?
p6590s1	Valor estimado de los alimentos recibidos
p6600	¿Recibió vivienda como parte de pago el mes pasado?
p6600s1	Valor estimado de la vivienda recibida
p6610	¿Utiliza transporte de la empresa para desplazarse al trabajo?
p6610s1	Valor estimado del transporte recibido
p6620	¿Recibió otros ingresos en especie (electrodomésticos, ropa, etc.)?
p6620s1	Valor estimado de los otros ingresos en especie
p6630s1	¿Recibió prima de servicios en los últimos 12 meses?
p6630s1a1	Valor recibido por prima de servicios
p6630s2	¿Recibió prima de navidad en los últimos 12 meses?
p6630s2a1	Valor recibido por prima de navidad
p6630s3	¿Recibió prima de vacaciones en los últimos 12 meses?
p6630s3a1	Valor recibido por prima de vacaciones
p6630s4	¿Recibió viáticos permanentes en los últimos 12 meses?
p6630s4a1	Valor recibido por viáticos permanentes
p6630s6	¿Recibió bonificaciones anuales en los últimos 12 meses?
p6630s6a1	Valor recibido por bonificaciones anuales
p6750	Ganancia u honorarios netos en la actividad/negocio el mes pasado
p3073	¿A cuántos meses corresponde lo que recibió?

p550	Ganancia neta del negocio/cosecha últimos 12 meses (centros poblados/rural)
p6800	Horas a la semana que trabaja normalmente en ese empleo
p6920	¿Está cotizando actualmente a un fondo de pensiones?
p7040	¿Tenía otro trabajo o negocio la semana pasada?
p7045	Horas trabajadas la semana pasada en el segundo trabajo
p7050	Ocupación en la segunda actividad
p7070	Ganancia del mes pasado en el segundo trabajo o negocio
p7090	¿Desea trabajar más horas?
p7110	¿Hizo diligencias para trabajar más horas en las últimas 4 semanas?
p7120	¿Estaba disponible para trabajar más horas la semana pasada?
p7140s1	Motivo para cambiar empleo: Mejorar utilización de capacidades/formación
p7140s2	Motivo para cambiar empleo: Mejorar ingresos
p7150	¿Hizo diligencias para cambiar de trabajo en las últimas 4 semanas?
p7160	¿Podría empezar un nuevo trabajo antes de un mes?
p7350	Ocupación en el último trabajo (Desocupados)
p7422	¿Recibió ingresos por trabajo el mes pasado? (Desocupados)
p7422s1	Valor recibido
p7495	¿Recibió pagos por arriendos y/o pensiones el mes pasado?
p7500s1	¿Recibió pagos por arriendos (casas, vehículos, etc.) el mes pasado?

p7500s1a1	Valor recibido el mes pasado por arriendos
p7500s2	¿Recibió pagos por pensiones o jubilaciones el mes pasado?
p7500s2a1	Valor recibido el mes pasado por pensiones/jubilaciones
p7500s3	¿Recibió pagos por pensión alimenticia el mes pasado?
p7500s3a1	Valor recibido el mes pasado por pensión alimenticia
p7505	¿Recibió dinero de otros hogares/instituciones o por intereses en los últimos 12 meses?
p7510s1	Dinero recibido de otros hogares/personas residentes en el país
p7510s1a1	Valor recibido
p7510s2	Dinero recibido de otros hogares/personas residentes fuera del país
p7510s2a1	Valor recibido
p7510s3	Ayudas en dinero de instituciones del país
p7510s3a1	Valor recibido
p7510s5	Dinero por intereses, utilidades o dividendos por inversiones
p7510s5a1	Valor recibido
p7510s6	Dinero por concepto de cesantías y/o intereses a las cesantías
p7510s6a1	Valor recibido
p7510s7	Dinero de otras fuentes diferentes a las anteriores
p7510s7a1	Valor recibido
pet	Población en edad de trabajar

oc	Ocupado
des	Desocupado
fft	Fuera de la fuerza de trabajo
impa	Ingreso monetario de la primera actividad antes de imputación
isa	Ingreso monetario de la segunda actividad antes de imputación
ie	Ingreso en especie antes de imputación
imdi	Ingreso por trabajo de desocupados e inactivos antes de imputación
iof1	Ingreso por intereses y dividendos antes de imputación
iof2	Ingreso por jubilaciones y pensiones antes de imputación
iof3h	Ingreso por ayudas de hogares antes de imputación
iof3i	Ingreso por ayudas de instituciones antes de imputación
iof6	Ingreso por arriendos antes de imputación
cclasnr2	Estado de impa
cclasnr3	Estado de isa
cclasnr4	Estado de ie
cclasnr5	Estado de imdi
cclasnr6	Estado de iof1
cclasnr7	Estado de iof2
cclasnr8	Estado de iof3
cclasnr11	Estado de iof6

impaes	Ingreso monetario de primera actividad imputado
isaes	Ingreso monetario de segunda actividad imputado
iees	Ingreso en especie imputado
imdies	Ingreso por trabajo de desocupados e inactivos imputado
iof1es	Ingreso por intereses y dividendos imputado
iof2es	Ingreso por jubilaciones y pensiones imputado
iof3hes	Ingreso por ayudas de hogares imputado
iof3ies	Ingreso por ayudas de instituciones imputado
iof6es	Ingreso por arriendos imputado
ingtob	Ingreso total observado
ingtotes	Ingreso total imputado
ingtot	Ingreso total
fex_c	Factor de expansión anualizado
fex_dpto	Factor de expansión departamental
dpto	Departamento

Archivo: Hogares

Casos: 276.666 | **Variables:** 23

Variable	Descripción
directorio	Llave de vivienda
secuencia_p	Llave de hogar
mes	Mes
clase	Clase

dominio	Dominio
ciudad_sinam	Ciudades capitales (sin Área Metropolitana)
p5090	La vivienda ocupada por este hogar es
p5100	¿Cuánto pagan mensualmente por cuota de amortización?
p5130	Si tuviera que pagar arriendo, ¿cuánto estima que pagaría mensualmente?
nper	Personas en el hogar
npersug	Número de personas en la unidad de gasto
ingtug	Ingreso total de la unidad de gasto antes de imputación de arriendo
ingtotarr	Ingreso total de la unidad de gasto con imputación de arriendo
ingpcug	Ingreso per cápita de la unidad de gasto con imputación de arriendo
li	Línea de indigencia
lp	Línea de pobreza
pobre	Pobre
indigente	Indigente
npobres	Número de pobres
nindigentes	Número de indigentes
fex_c	Factor de expansión anualizado
fex_dpto	Factor de expansión departamental
dpto	Departamento

3.3 Restricción metodológica transversal: el factor de expansión

La GEIH es una encuesta de muestreo complejo: cada fila representa a un número variable de hogares o personas reales, indicado en `fex_c`. Esto condiciona toda consulta del proyecto:

En vez de	Usar
<code>COUNT(*) WHERE indigente = 1</code>	<code>SUM(fex_c) FILTER (WHERE indigente = 1)</code>
<code>AVG(ingtotug)</code>	<code>SUM(ingtotug * fex_c) / SUM(fex_c)</code>
<code>AVG(col)</code> sobre variable sesgada	<code>EXP(SUM(col_log * fex_c) / SUM(fex_c))</code>
<code>fex_c</code> en agregados departamentales	<code>fex_dpto</code>

Ignorar esta restricción produce cifras que parecen correctas pero no representan a la población, por eso se documenta en el README, en el modelo de datos y como comentario dentro del propio DDL.

4. Arquitectura

4.1 Flujo general y arquitectura de medallón

El pipeline recorre cuatro etapas: extracción desde los CSV en Google Drive, transformación en pandas, carga a PostgreSQL vía SQLAlchemy y EDA con `pd.read_sql` contra la base. En el notebook de personas la etapa de transformación está organizada además como arquitectura de medallón:

- **Bronce** — copia fiel de las 25 columnas seleccionadas del CSV, sin modificar nada. Sobre ella se hace el perfilado: mapa de calor de nulos, conteos absolutos y porcentuales, tipos de dato, duplicados e histogramas de outliers.
- **Plata** — decisiones documentadas. Cada bloque de nulos se investiga cruzándolo con edad, pet y p6240 antes de decidir; la conclusión fue que todos son estructurales y no deben imputarse. Aquí también se construye `condicion_laboral` a partir de `oc/des/fft` y se convierte pet a booleano.
- **Oro** — derivaciones para consumo analítico: etiquetas legibles (sexo, grupo_edad, nivel_educativo), la bandera `tiene_segundo_empleo` y las columnas logarítmicas. La capa Oro solo agrega columnas: ninguna original se modifica ni se elimina, de modo que cualquier consulta escrita contra la versión anterior del modelo sigue devolviendo el mismo resultado.

El medallón describe cómo se refinó el dato; el esquema de galaxia describe cómo queda organizado el dato final para consulta. Son complementarios, no alternativos.

4.2 Modelo de datos: esquema de galaxia

Por qué galaxia y no estrella

Nuestro proyecto combina dos fuentes con granularidad distinta: en Hogares.csv una fila es un hogar; en Personas.csv, una persona. Forzar ambos niveles en una sola tabla de hechos duplicaría las medidas del hogar (ingreso, condición de pobreza) tantas veces como integrantes tenga, rompiendo la aditividad: sumar ingtotug sobre esa tabla contaría varias veces el mismo ingreso.


La solución es un esquema de galaxia o constelación: dos tablas de hechos que comparten dimensiones conformadas, más una dimensión propia del segundo hecho. Es la generalización del esquema estrella cuando hay más de un proceso de negocio analizado con las mismas dimensiones.

Tablas del modelo

Tabla	Grano	Rol
dim_tiempo	1 fila por mes	Conformada
dim_geografia	1 fila por dpto + dominio + ciudad_sinam + clase	Conformada
dim_hogar	1 fila por hogar (directorio + secuencia_p)	Conformada y puente entre ambos hechos
dim_persona	1 fila por persona (directorio + secuencia_p + orden)	Propia de fact_personas
fact_hogares	1 fila por hogar	Ingreso, líneas, brechas, banderas pobre/indigente, fex_c
fact_personas	1 fila por persona	Ingresos, empleo principal y secundario, edad, condición laboral, pesos

dim_hogar es la pieza clave: fact_personas la referencia por id_hogar para llegar a la condición de pobreza del hogar sin duplicar las medidas del hogar en cada fila de persona. Ninguna de las preguntas de personas podría responderse sin ese puente, y esa es la razón práctica por la que el esquema tiene que ser de galaxia.

Diagrama



Esquema de galaxia del proyecto: dos tablas de hechos con dimensiones conformadas y `dim_hogar` como puente.

`dim_hogar` es la pieza clave: `fact_personas` la referencia por `id_hogar` para llegar a la condición de pobreza del hogar sin duplicar las medidas del hogar en cada fila de persona. Ninguna de las preguntas de personas podría responderse sin ese puente, y esa es la razón práctica por la que el esquema tiene que ser de galaxia.

Decisiones de diseño documentadas

1. `clase_desc`, `tipo_zona`, `categoría_tenencia` y `tamaño_hogar_rango` se persisten en las dimensiones, no solo en el DataFrame de trabajo. Así el EDA agrupa por etiquetas legibles directamente en SQL, sin reconstruir la lógica con CASE WHEN en cada consulta.
2. Los códigos originales (p3042, p3271, p6040) se conservan junto a su etiqueta: permiten ordenar por progresión educativa o filtrar por edad exacta, cosa que un bucket de texto no habilita, y mantienen la trazabilidad hacia el CSV.
3. `nper` crudo permanece en `fact_hogares` aunque `dim_hogar` tenga su versión categorizada: la correlación ponderada tamaño-vs-indigencia necesita el valor numérico exacto, un bucket de texto no sirve como insumo de una covarianza.

4. Ambas brechas (pobreza e indigencia) viajan al hecho; la de indigencia es la variable central de la pregunta sobre profundidad.
5. Tiene_segundo_empleo se modela como medida (0/1) en el hecho y no como atributo de la dimensión, porque se consume ponderada: $\text{SUM}(\text{tiene_segundo_empleo} * \text{fex_c}) / \text{SUM}(\text{fex_c})$. Es el mismo criterio con el que pobre e indigente viven en fact_hogares.
6. Las columnas _log conviven con sus originales en lugar de reemplazarlas. La versión original permite sumas y totales, la logarítmica permite promedios robustos. Eliminar una de las dos obligaría a recalcularla en cada consulta.
7. No se implementó la junk dimension dim_condicion_pobreza: con solo dos banderas correlacionadas y consultas que las usan en expresiones ponderadas ($\text{SUM}(\text{indigente} * \text{fex_c}) / \text{SUM}(\text{fex_c})$), el join adicional sobre 276.666 filas no compensa. Queda registrada como mejora si en una entrega posterior se construye un dashboard con navegación por categorías.
8. Surrogate keys con prefijo id_ en todas las dimensiones, conservando las llaves naturales como atributos para trazabilidad hacia el CSV original.
9. Sin SCD tipo 2: el dataset es una muestra transversal de una sola vigencia, sin hogares repetidos entre meses. Todas las dimensiones son tipo 0/1. Si se incorporan varias vigencias con panel real, habría que reevaluar dim_hogar y agregar anio a dim_tiempo.

4.3 Flujo general y arquitectura de medallón

Ambos notebooks siguen el mismo procedimiento de carga: DDL explícito (DROP + CREATE con llaves primarias y foráneas), carga con to_sql y chunksize de 10.000 filas, y verificación final con SELECT COUNT(*) sobre cada tabla.

En personas se añadieron tres controles adicionales, porque los merges contra las dimensiones ya cargadas son el punto donde el modelo se puede romper en silencio:

1. Unicidad de la llave natural en dim_persona: si directorio + secuencia_p + orden se repitiera, el merge duplicaría filas y la carga fallaría contra el PRIMARY KEY.
2. Conteo de filas antes y después de los cuatro merges, para descartar que alguno haya multiplicado registros.
3. Conteo de nulos en id_persona, id_hogar, id_geografia e id_tiempo: cualquier nulo indicaría una persona que no encontró su hogar o su geografía en las dimensiones conformadas, es decir, una violación de integridad referencial que Postgres rechazaría al insertar.

5. Stack tecnológico

Capa	Tecnología	Justificación
------	------------	---------------

Entorno de desarrollo	de Google Colab + Google Drive	Sin instalación local, fácil de compartir entre el equipo, el <code>drive.mount()</code> da acceso directo a los CSV compartidos.
Lenguaje y transformación	Python (pandas, numpy)	Mejor manejo de datasets grandes y limpieza de datos
Base de datos	PostgreSQL gestionado en Supabase	Motor relacional en la nube, no requiere infraestructura propia del equipo, accesible para todos los integrantes
Conexión Python ↔ BD	SQLAlchemy + psycopg2-binary	Para cargar los DataFrames de pandas directamente a las tablas de Postgres
Visualización	matplotlib, seaborn	Barras, histogramas ponderados y mapas de calor de nulos; suficientes para el EDA y sin dependencias pesadas en Colab
Control de versiones	Git / GitHub	Permite el orden y deja evidencia del aporte individual
Gestión de credenciales	getpass, .env + .gitignore	Evita que contraseñas y keys queden versionadas

6. Resumen del EDA y visualizaciones

Todas las consultas se ejecutan contra PostgreSQL con `pd.read_sql` y ponderan por `fex_c` o `fex_dpto` en los cortes departamentales, dentro del propio SQL. Ningún gráfico se construye a partir de los CSV originales.

6.1 Tamaño del hogar y pobreza extrema

Consulta: tasa de indigencia ponderada por `tamano_hogar_rango`, uniendo `fact_hogares` con `dim_hogar`. Visualización: gráfico de barras.

Tamaño del hogar	% en indigencia (ponderado)
1–2 personas	4,44 %
3–4 personas	8,17 %
5 o más personas	16,84 %

La correlación ponderada entre nper (número de personas) y su clasificación en indigencia, calculada íntegramente en SQL con una CTE de medias ponderadas, es $r = 0,153$: positiva pero débil. La lectura correcta es que el tamaño del hogar es un factor de riesgo consistente (la tasa casi se cuadruplica entre extremos) pero no un determinante suficiente: hogares grandes con ingresos altos no caen en indigencia, y el ingreso per cápita depende del ingreso total tanto como del número de personas entre las que se reparte.

6.2 Distribución geográfica

Consulta: ingreso per cápita promedio ponderado por departamento, uniendo con dim_geografia. Visualización: barras horizontales de los diez departamentos con menor ingreso.

Menor ingreso per cápita: Chocó (~\$596.400), La Guajira (~\$597.965), Sucre (~\$768.361), Córdoba (~\$821.031), Cauca (~\$876.781). Mayor ingreso per cápita: Bogotá D.C. (~\$2.734.383), Antioquia (~\$1.896.476), Cundinamarca (~\$1.637.964), Valle del Cauca (~\$1.586.424), Risaralda (~\$1.513.259).

La razón entre Bogotá y Chocó es cercana a 4,6 a 1. La concentración territorial es marcada y coincide con los departamentos de periferia.

6.3 Urbano frente a rural, y profundidad de la pobreza

¿Los hogares con mayor número de personas presentan mayor probabilidad de estar en pobreza extrema?

Consulta: porcentaje ponderado de hogares pobres e indigentes por tipo_zona. Visualización: barras agrupadas.

Zona	% pobre	% indigente
Áreas Metropolitanas	17,60 %	4,38 %
Resto urbano	23,30 %	7,58 %
Rural	32,30 %	14,77 %

La indigencia rural más que triplica la de ciudades capitales, y el gradiente capital → resto urbano → rural es monótono en ambos indicadores.

Profundidad. A nivel nacional, 42,2 % de pobreza y 7,51 % de indigencia ponderadas ($\approx 1.367.073$ hogares en indigencia sobre $\approx 18.199.756$ representados). La brecha mediana ponderada de los hogares indigentes es de 34,1 % por debajo de la línea de indigencia: la mitad de ellos necesitaría aumentar su ingreso per cápita en más de un tercio solo para alcanzar el umbral. La visualización es un histograma ponderado por fex_c de la brecha porcentual, que muestra que la masa de hogares no se concentra justo debajo de la línea sino claramente alejada de ella.

Esta distinción entre incidencia (cuántos) y profundidad (qué tan lejos) es el aporte analítico central del proyecto: dos territorios con la misma tasa de pobreza pueden requerir intervenciones de magnitud muy distinta.

6.4 Capa Oro de personas: por qué media geométrica


El perfilado de outliers de la capa Plata mostró que ingtot, p6500 y p7070 son fuertemente asimétricas a la derecha: unos pocos ingresos muy altos desplazan el promedio aritmético por encima de lo que gana la persona típica. Por eso la capa Oro persiste las versiones logarítmicas (log1p) de las variables monetarias y de horas, y el EDA las agrega así:

```
SELECT EXP( SUM(salario_principal_log * fex_c) / SUM(fex_c) ) - 1 AS salario_geometrico  
FROM fact_personas WHERE salario_principal_log IS NOT NULL;
```

El resultado es una media geométrica ponderada, robusta a los valores extremos. Se usa log1p y no log porque hay ceros legítimos (personas sin ingreso propio) y $\log1p(0) = 0$ en vez de infinito. Los valores nulos estructurales se mantienen nulos y no se convierten en cero: "no tiene segundo empleo" no es lo mismo que "gana 0 en su segundo empleo". En las consultas de nivel de ingreso se excluyen además los ceros, porque la pregunta es sobre el monto que percibe quien percibe algo.

6.5 Pregunta 4 - Remuneración y multiempleo

Los ocupados de hogares en indigencia ganan en promedio geométrico ponderado \$411.543 en su trabajo principal, frente a \$844.334 en hogares pobres no indigentes y \$1.534.626 en hogares no pobres: una razón de casi 4 a 1 entre extremos. El multiempleo sigue el patrón inverso al esperado: los ocupados de hogares en indigencia presentan la mayor tasa de segundo empleo (5,30 %), ligeramente por encima de los pobres no indigentes (4,07 %) y los no pobres (3,97 %). Esto sugiere que el segundo empleo en los hogares más vulnerables no es una señal de oportunidad sino de necesidad: el trabajo principal no alcanza y se complementa con otro, aunque ambos sean de baja remuneración. La brecha de salario es, pues, el indicador más relevante de la pregunta: no es que los pobres trabajen menos empleos, sino que cada empleo paga menos.




6.6 Pregunta 5 - Pobreza extrema a nivel de personas

Los diez departamentos con mayor proporción de personas en pobreza extrema son, en orden descendente: Chocó (44,26 %), La Guajira (33,84 %), Magdalena (21,47 %), Sucre (19,07 %), Cauca (18,54 %), Córdoba (17,92 %), Cesar (16,46 %), Bolívar (15,68 %), Huila (14,47 %) y Caquetá (12,30 %). Chocó y La Guajira destacan por márgenes amplios sobre el resto. La concentración territorial coincide con los departamentos que ya aparecían en los diez de menor ingreso per cápita del notebook de hogares, lo que confirma la coherencia entre ambas mediciones. La comparación entre ambas tasas (indigencia a nivel de hogar y a nivel de persona) permite además verificar el efecto del tamaño del hogar documentado en la pregunta 1: los departamentos con mayor pobreza extrema tienden también a tener hogares más numerosos, por lo que su tasa de personas en indigencia es sistemáticamente más alta que su tasa de hogares.




6.7 Pregunta 6 - Sexo y edad

La pobreza extrema afecta de manera más intensa a la infancia y la adolescencia. Los grupos de 0 - 5 años (17,20 % hombres / 17,46 % mujeres) y 6-11 años (16,89 % / 16,49 %) presentan las tasas más altas, casi tres veces las del grupo 29-45. La tasa desciende de forma monotonía desde la niñez hasta los adultos mayores. Las diferencias por sexo son pequeñas en los grupos de menor edad, pero se amplían notablemente en las edades de 18-28 y 29-45, donde las mujeres superan a los hombres en casi 3 puntos porcentuales (9,69 % vs 6,99 % y 9,41 % vs 6,56 % respectivamente), lo que puede asociarse a la mayor presencia femenina fuera de la fuerza de trabajo y a brechas salariales en esa etapa. En los grupos de 46-60 y 61+ la brecha se reduce y se invierte levemente.



6.8 Pregunta 7 - Nivel educativo

El gradiente educativo es el más pronunciado de todo el análisis: la tasa de indigencia pasa de 17,28 % en personas sin ningún nivel educativo a 0,22 % en quienes tienen doctorado. Los niveles básicos concentran las tasas más altas —Preescolar 16,17 %, Básica primaria 10,40 %, Básica secundaria 10,45 %—, mientras que a partir de la formación técnica profesional la tasa cae por debajo del 5 %. La educación media (bachillerato clásico 6,90 %, bachillerato técnico 5,71 %) marca el punto de inflexión. El ingreso geométrico sigue el patrón complementario: desde \$415.295 para Ninguno hasta \$7.701.759 para Doctorado, una diferencia de casi 18 a 1. Cabe anotar que la causalidad no es directa —la educación más alta también se correlaciona con zona urbana y sector formal—, pero la asociación es la más fuerte observada en todo el proyecto.



6.9 Pregunta 8 - Distribución del ingreso personal

El ingreso geométrico ponderado de las personas en hogares indigentes es \$224.230, frente a \$588.865 en hogares pobres no indigentes y \$1.486.001 en hogares no pobres. La distancia entre la media aritmética y la geométrica (\$339.460 vs \$224.230 para el grupo indigente, y \$2.354.345 vs \$1.486.001 para el no pobre) confirma que la distribución del ingreso es fuertemente asimétrica en todos los grupos, y que la media aritmética sobreestima el ingreso típico: de ahí la necesidad de las columnas **_log** de la capa Oro. El histograma de distribución por grupo muestra que las curvas de hogares pobres e indigentes se concentran en el tramo \$0,01M - \$0,44M, mientras que la de hogares no pobres tiene su pico en torno a \$1,20M. Las tres curvas se solapan parcialmente entre \$0,16M y \$0,44M, lo que indica que el ingreso por sí solo no separa perfectamente los grupos: hay personas de hogares no pobres con ingresos bajos y personas de hogares pobres con ingresos relativamente más altos, posiblemente por el efecto del tamaño del hogar sobre el ingreso per cápita que determina la condición de pobreza.

