

ETL-Project: First Delivery

Autores:

Santiago Lourido Rodríguez

Código: 2248394

santiago.lourido@uao.edu.co

Laura Valentina Loaiza Díaz

Código: 2248519

laura_val.loaiza@uao.edu.co

Sebastián Alejandro Jiménez Solís

Código: 2248450

sebastian.jimenez_s@uao.edu.co

Carlos Fabián Cordoba Duque

Código: 2247550

carlos_fab.cordoba@uao.edu.co

Docente:

Daniel Bernal

Facultad:

Ingeniería y Ciencias Básicas

Curso:

ETL

Cali – Valle del cauca

14 de septiembre de 2026



1. Resumen ejecutivo

Este informe documenta el diseño y la implementación de un pipeline ETL completo sobre los microdatos de la Gran Encuesta Integrada de Hogares (GEIH) del DANE, orientado a analizar la pobreza y la pobreza extrema en Colombia en el marco del ODS 1: Fin de la Pobreza.

El pipeline extrae dos archivos CSV (hogares y personas), los modela en un esquema de galaxia con dos tablas de hechos y cuatro dimensiones, los migra a PostgreSQL gestionado en Supabase, y responde las preguntas de negocio mediante consultas SQL ejecutadas contra la base de datos, no contra los archivos originales.

2. El dataset seleccionado y por qué

2.1 Justificación frente al ODS

El ODS 1 de la Agenda 2030 busca poner fin a la pobreza en todas sus formas. Su primera meta se mide sobre la proporción de población que vive por debajo de una línea internacional de pobreza, y su segunda meta sobre las líneas de pobreza nacionales. El dataset elegido contiene exactamente ese tipo de medición para Colombia: el DANE calcula el ingreso per cápita de la unidad de gasto (ingpcug) y lo contrasta con la línea de pobreza (lp) y la línea de indigencia (li), produciendo las banderas oficiales pobre e indigente.

Es decir, no se trata de un dataset del que haya que *inferir* pobreza mediante proxies: es la fuente con la que el país produce su estadística oficial de pobreza monetaria. Eso hace que el vínculo con el ODS sea directo y verificable.

2.2 Por qué dos archivos y no uno

Hogares.csv responde dónde y con qué profundidad ocurre la pobreza, pero no dice quiénes la viven. Personas.csv aporta sexo, edad, nivel educativo, condición laboral e ingresos individuales, y comparte con el primero la llave directorio + secuencia_p. Usar ambos permite cruzar la condición de pobreza del hogar con las características de sus integrantes, que es donde están las preguntas más interesantes del proyecto (multiempleo, baja remuneración, educación).

3. Requerimientos y criterios de evaluación de las fuentes

3.1 Requerimientos del análisis

Requerimientos funcionales

1. Cuantificar la incidencia de pobreza y pobreza extrema a nivel nacional, departamental y por tipo de zona (capital, resto urbano, rural).

2. Medir la profundidad de la pobreza, no solo su incidencia, mediante una brecha de ingreso respecto de cada línea.
3. Relacionar el tamaño del hogar con la probabilidad de estar en pobreza extrema.
4. Caracterizar a las personas en pobreza extrema por sexo, edad, nivel educativo y situación laboral.
5. Entregar todas las respuestas como consultas ejecutables sobre una base de datos relacional, con visualizaciones asociadas.

Requerimientos no funcionales

6. Toda cifra agregada debe ser estadísticamente representativa: ponderada por el factor de expansión, nunca contando filas.
7. Las decisiones de limpieza deben quedar documentadas y ser reproducibles; no se imputa ni se elimina sin justificación escrita.
8. Las credenciales de la base de datos no pueden quedar en el código versionado.
9. El pipeline debe poder re-ejecutarse de principio a fin por cualquier integrante del equipo sin configuración manual adicional más allá de sus credenciales.

3.2 Criterios de evaluación aplicados a las fuentes

Se evaluaron los cuatro criterios exigidos por la rúbrica: disponibilidad, relevancia, estructura y calidad.

Hogares.csv — grano hogar

Criterio	Evaluación
Disponibilidad	Microdato público del DANE, descargable sin costo ni restricción, acompañado de ficha técnica y diccionario de variables. Formato CSV plano, sin dependencias de licencia
Relevancia	Contiene las variables de medición oficial de pobreza monetaria (ingpcug, lp, li, pobre, indigente, npobres, nindigentes). Vínculo directo con el ODS 1
Estructura	276.666 filas × 23 columnas. Llave directorio + secuencia_p verificada como única (0 duplicados). Rangos de li y lp contrastados contra los valores oficiales del DANE: sin valores fuera de rango. Supera el mínimo de la rúbrica (10.000 filas / 10 variables)
Calidad	Nulos concentrados en tres columnas y todos estructurales: p5100 (96,7 %) y p5130 (40,5 %) dependen del tipo de tenencia de vivienda; ciudad_sinam (33,4 %) solo aplica a hogares residentes en ciudad capital. Ninguna variable del análisis de pobreza presenta nulos. 2.195 hogares (0,79 %) con ingreso total ≤ 0 se marcaron con bandera en vez de eliminarse. Discrepancia nper vs npersug en 1.225 filas (0,44 %), esperable por definición metodológica

Personas.csv — grano persona

Criterio	Evaluación
Disponibilidad	Mismo origen, vigencia y ficha técnica que Hogares.csv
Relevancia	Aporta las dimensiones individuales (sexo, edad, educación, empleo, ingreso) necesarias para las preguntas de personas
Estructura	773.932 filas × 133 columnas, de las cuales se seleccionaron 23 para el análisis. Llave directorio + secuencia_p + orden; comparte directorio + secuencia_p con hogares, habilitando la relación 1 hogar → N personas sin ambigüedad
Calidad	Sin duplicados. El perfilado de nulos se hizo columna por columna cruzando con edad, pet y p6240: en p3042 (nivel educativo) los nulos corresponden mayoritariamente a menores fuera de edad escolar; en p6800 y p6500 a personas cuya actividad principal no es trabajar; en p7040, p7070 y p7045 a personas sin segundo empleo. Todos estructurales → no se imputan ni se eliminan. Se detectó además una inconsistencia en pet: personas mayores de 60 años marcadas como población en edad de trabajar, por lo que todo indicador laboral debe filtrar pet y fft conjuntamente

Adecuación conjunta

Ambas fuentes comparten llave natural, período de referencia y diseño muestral (fex_c y fex_dpto comparables). Esto permite construir el esquema de galaxia con dimensiones conformadas sin duplicar atributos ni comprometer la representatividad estadística, siempre que los agregados se calculen ponderados.

3.3 Restricción metodológica transversal: el factor de expansión

La GEIH es una encuesta de muestreo complejo: cada fila representa a un número variable de hogares o personas reales, indicado en fex_c. Esto condiciona toda consulta del proyecto:

En vez de	Usar
COUNT(*) WHERE indigente = 1	SUM(fex_c) FILTER (WHERE indigente = 1)
AVG(ingtotug)	SUM(ingtotug * fex_c) / SUM(fex_c)
AVG(col) sobre variable sesgada	EXP(SUM(col_log * fex_c) / SUM(fex_c))
fex_c en agregados departamentales	fex_dpto

Ignorar esta restricción produce cifras que parecen correctas pero no representan a la población; por eso se documenta en el README, en el modelo de datos y como comentario dentro del propio DDL.

4. Arquitectura

4.1 Modelo de datos: esquema de galaxia

Por qué galaxia y no estrella


Nuestro proyecto combina dos fuentes con grano distinto: en Hogares.csv una fila es un hogar; en Personas.csv, una persona. Forzar ambos niveles en una sola tabla de hechos duplicaría las medidas del hogar (ingreso, condición de pobreza) tantas veces como integrantes tenga, rompiendo la aditividad: sumar ingtotug sobre esa tabla contaría varias veces el mismo ingreso.

La solución es un esquema de galaxia o constelación: dos tablas de hechos que comparten dimensiones conformadas, más una dimensión propia del segundo hecho. Es la generalización del esquema estrella cuando hay más de un proceso de negocio analizado con las mismas dimensiones.

Tablas del modelo

Tabla	Grano	Rol
dim_tiempo	1 fila por mes	Conformada
dim_geografia	1 fila por dpto + dominio + ciudad_sinam + clase	Conformada
dim_hogar	1 fila por hogar (directorio + secuencia_p)	Conformada y puente entre ambos hechos
dim_persona	1 fila por persona (directorio + secuencia_p + orden)	Propia de fact_personas
fact_hogares	1 fila por hogar	Ingreso, líneas, brechas, banderas pobre/indigente, fex_c
fact_personas	1 fila por persona	Ingresos, empleo principal y secundario, edad, condición laboral, pesos

Diagrama



Esquema de galaxia del proyecto: dos tablas de hechos con dimensiones conformadas y dim_hogar como puente

dim_hogar es la pieza clave: fact_personas la referencia por id_hogar para llegar a la condición de pobreza del hogar sin duplicar las medidas del hogar en cada fila de persona. Ninguna de las preguntas de personas podría responderse sin ese puente, y esa es la razón práctica por la que el esquema tiene que ser de galaxia.

Decisiones de diseño documentadas

1. clase_desc, tipo_zona, categoria_tenencia y tamano_hogar_rango se persisten en las dimensiones, no solo en el DataFrame de trabajo. Así el EDA agrupa por etiquetas legibles directamente en SQL, sin reconstruir la lógica con CASE WHEN en cada consulta.
2. nper crudo permanece en fact_hogares aunque dim_hogar tenga su versión categorizada: la correlación ponderada tamaño-vs-indigencia necesita el valor numérico exacto, un bucket de texto no sirve como insumo de una covarianza.
3. Ambas brechas (pobreza e indigencia) viajan al hecho; la de indigencia es la variable central de la pregunta sobre profundidad.

4. No se implementó la junk dimension `dim_condicion_pobreza`: con solo dos banderas correlacionadas y consultas que las usan en expresiones ponderadas ($\text{SUM}(\text{indigente} * \text{fex_c}) / \text{SUM}(\text{fex_c})$), el join adicional sobre 276.666 filas no compensa. Queda registrada como mejora si en una entrega posterior se construye un dashboard con navegación por categorías.
5. Surrogate keys con prefijo `id_` en todas las dimensiones, conservando las llaves naturales como atributos para trazabilidad hacia el CSV original.
6. Sin SCD tipo 2: el dataset es una muestra transversal de una sola vigencia, sin hogares repetidos entre meses. Todas las dimensiones son tipo 0/1. Si se incorporan varias vigencias con panel real, habría que reevaluar `dim_hogar` y agregar `anio` a `dim_tiempo`.

5. Stack tecnológico

Capa	Tecnología	Justificación
Entorno de desarrollo	de Google Colab + Google Drive	Sin instalación local, fácil de compartir entre el equipo; <code>drive.mount()</code> da acceso directo a los CSV compartidos.
Lenguaje y transformación	Python (pandas, numpy)	Manejo más severo de datasets grandes (276k filas) y limpieza de datos
Base de datos	PostgreSQL gestionado en Supabase	Motor relacional en la nube, no requiere infraestructura propia del equipo, accesible para todos los integrantes
Conexión Python ↔ BD	SQLAlchemy + psycopg2-binary	Para cargar los DataFrames de pandas directamente a las tablas de Postgres
Visualización	matplotlib, seaborn	Barras, histogramas ponderados y mapas de calor de nulos; suficientes para el EDA y sin dependencias pesadas en Colab
Control de versiones	Git / GitHub	Permite el orden y deja evidencia del aporte individual
Gestión de credenciales	getpass, .env + .gitignore	Evita que contraseñas y keys queden versionadas

6. Resumen del EDA y visualizaciones

Todas las consultas se ejecutan contra PostgreSQL con `pd.read_sql` y ponderan por `fex_c` dentro del propio SQL.

6.1 Tamaño del hogar y pobreza extrema

Consulta: tasa de indigencia ponderada por `tamano_hogar_rango`, uniendo `fact_hogares` con `dim_hogar`. Visualización: gráfico de barras.

Tamaño del hogar	% en indigencia (ponderado)
1–2 personas	4,44 %
3–4 personas	8,17 %
5 o más personas	16,84 %

La correlación ponderada entre `nper` e indigente, calculada íntegramente en SQL con una CTE de medias ponderadas, es $r = 0,153$: positiva pero débil. La lectura correcta es que el tamaño del hogar es un factor de riesgo consistente (la tasa casi se cuadruplica entre extremos) pero no un determinante suficiente: hogares grandes con ingresos altos no caen en indigencia, y el ingreso per cápita depende del ingreso total tanto como del número de personas entre las que se reparte.

6.2 Distribución geográfica

Consulta: ingreso per cápita promedio ponderado por departamento, uniendo con `dim_geografia`. Visualización: barras horizontales de los diez departamentos con menor ingreso.

Menor ingreso per cápita: Chocó (~\$596.400), La Guajira (~\$597.965), Sucre (~\$768.361), Córdoba (~\$821.031), Cauca (~\$876.781). Mayor ingreso per cápita: Bogotá D.C. (~\$2.734.383), Antioquia (~\$1.896.476), Cundinamarca (~\$1.637.964), Valle del Cauca (~\$1.586.424), Risaralda (~\$1.513.259).

La razón entre Bogotá y Chocó es cercana a 4,6 a 1. La concentración territorial es marcada y coincide con los departamentos de periferia.

6.3 Urbano frente a rural, y profundidad de la pobreza

Consulta: porcentaje ponderado de hogares pobres e indigentes por `tipo_zona`. Visualización: barras agrupadas.

Zona	% pobre	% indigente
Ciudad capital	17,60 %	4,38 %
Resto urbano	23,30 %	7,58 %
Rural	32,30 %	14,77 %

La indigencia rural más que triplica la de ciudades capitales, y el gradiente capital → resto urbano → rural es monótono en ambos indicadores.

Profundidad. A nivel nacional, 22,35 % de pobreza y 7,51 % de indigencia ponderadas ($\approx 1.367.073$ hogares en indigencia sobre $\approx 18.199.756$ representados). La brecha mediana ponderada de los hogares indigentes es de 34,1 % por debajo de la línea de indigencia: la mitad de ellos necesitaría aumentar su ingreso per cápita en más de un tercio solo para alcanzar el umbral. La visualización es un histograma ponderado por `fex_c` de la brecha porcentual, que muestra que la masa de hogares no se concentra justo debajo de la línea sino claramente alejada de ella.

Esta distinción entre incidencia (cuántos) y profundidad (qué tan lejos) es el aporte analítico central del proyecto: dos territorios con la misma tasa de pobreza pueden requerir intervenciones de magnitud muy distinta.

6.4 Análisis a nivel de personas

Sobre `Personas.csv` se completaron las capas bronce y plata: selección de 23 variables de las 133 originales, perfilado de nulos columna por columna, verificación de duplicados y revisión de outliers mediante histogramas. Los hallazgos relevantes para el modelado fueron dos: (i) todos los nulos analizados son estructurales y no deben imputarse, y (ii) el campo `pet` es insuficiente por sí solo para delimitar población laboralmente activa, por lo que debe combinarse con `fft`.

En la capa oro se calcularon las columnas `_log` (`log1p`) de las variables monetarias y de horas, cuya distribución es fuertemente asimétrica. El procedimiento correcto de agregación, documentado para el equipo, es promediar la versión logarítmica ponderada y aplicar `EXP()` al resultado, obteniendo una media geométrica robusta a los valores extremos:

```
SELECT EXP( SUM(salario_trabajo_principal_log * fex_c) / SUM(fex_c) ) AS
salario_geometrico
FROM fact_personas
WHERE salario_trabajo_principal IS NOT NULL;
```

La carga de `dim_persona` y `fact_personas` a PostgreSQL y el EDA correspondiente quedan como cierre pendiente de esta entrega; el diseño, el DDL y las consultas ya están definidos en la documentación del repositorio.